Monitorización de un modelo de fraude financiero

Proyecto DataCamp 2104 · Informe técnico y ejecutivo en español

Resultado: la exactitud estimada y la observada señalan deterioro conjunto en abril, mayo y junio de 2019. El drift del tiempo desde el inicio de sesión es la señal más asociada al cambio de rendimiento. El importe medio de junio también activa una alerta.

Entregable requerido	Resultado calculado
months_with_performance_alerts	april_2019, may_2019, june_2019
highest_correlation_feature	time_since_login_min
alert_avg_transaction_amount	3069.8184 GBP (junio de 2019)

Qué cambia en producción

La exactitud agregada pasa de **94.37 %** en noviembre de 2018 a marzo de 2019 a **91.48 %** en abril-junio de 2019. La caída es de **2.90 puntos porcentuales**; la tasa de error crece un **51.5 %** relativo.

Las operaciones realizadas antes de un minuto del login pasan del **5.31 %** al **0.19 %**. Quedan 28 operaciones de ese tipo en los tres meses de alerta. El cambio afecta a ambas clases, por lo que no prueba por sí solo una adaptación deliberada de los defraudadores.

Alcance y estado

Se completaron la primera prueba, su revisión, una versión mejorada y controles independientes sobre los CSV originales. **DataCamp aprobó la solución el 9 de noviembre de 2026 y otorgó 1500 XP** en la cuenta HECTOR AMERICO TORRES HUAMANI. Se evaluaron predicciones existentes, sin reentrenar el modelo. La sección 9 documenta la aprobación y su alcance.

Los datos son un caso educativo. No se dispone de evidencia de que describan toda la operativa de un banco real. Los importes de fraudes no detectados se consideran exposición del conjunto, no pérdidas bancarias confirmadas.

1. Contexto, objetivo y datos

El caso presenta a Poundbank, un banco de Londres cuyo modelo de detección de fraude pierde exactitud después del despliegue. El papel del analista es vigilar el comportamiento temporal y priorizar qué cambios investigar. La plataforma recomienda NannyML. [1]

Archivo	Uso	Tamaño y cobertura
reference.csv	Referencia de test: ajustar monitores y límites	50.207 filas; enero-octubre de 2018
analysis.csv	Producción: estimar y contrastar resultados	39.967 filas; noviembre de 2018-junio de 2019

Columna	Interpretación y papel
timestamp	Fecha y hora de la transacción; define los bloques mensuales.
time_since_login_min	Minutos desde el inicio de sesión; variable numérica de entrada.
transaction_amount	Importe de la operación en libras esterlinas (GBP).
transaction_type	Tipo: CASH-OUT, PAYMENT, CASH-IN o TRANSFER; puede faltar.
is_first_transaction	Indicador de primera transacción; se trata como categórico binario.
user_tenure_months	Antigüedad del usuario en meses; variable numérica.
is_fraud	Etiqueta real: 1 fraude, 0 legítima. Permite calcular rendimiento observado.
predicted_fraud_proba	Probabilidad de fraude emitida por el modelo; entrada de CBPE.
predicted_fraud	Decisión binaria suministrada por el modelo; se conserva sin alteración.

Hay cinco variables de entrada, una fecha, una etiqueta real y dos salidas del modelo. Las etiquetas de producción están disponibles para validar la estimación; se excluyen expresamente de la llamada a CBPE. No se proporciona el modelo entrenado ni su conjunto de entrenamiento.

2. Requisitos y proceso seguido

Paso	Acción	Criterio de aceptación
1. Recopilar	Leer enunciado, descargar notebook original y ambos CSV.	Procedencia original y huellas SHA-256 registradas.
2. Auditar	Validar esquema, fechas, clases, probabilidades, nulos y duplicados.	Datos válidos y referencia anterior a producción.
3. Primera prueba	CBPE + exactitud observada; drift KS/chi2; media mensual.	Obtener las tres variables exigidas por DataCamp.
4. Revisar	Comprobar métricas independientes, nulos, meses y ranking.	Detectar límites metodológicos y evitar conclusiones causales.
5. Mejorar	Ranking solo de producción, nulos explícitos y robustez.	Respuestas estables y mayor trazabilidad del diagnóstico.
6. Entregar	Notebook ejecutado, código, tablas, figuras e informe.	Reejecución documentada y resultados verificables.

Análisis previo de calidad

Comprobación	Referencia	Producción
Filas / columnas	50.207 / 9	39.967 / 9
Filas y fechas duplicadas	0 / 0	0 / 0
Nulos en transaction_type	3.052 (6.08 %)	2.453 (6.14 %)
Nulos en el resto de columnas	0	0
Fraude confirmado	49.98 %	49.94 %
Orden y separación temporal	Ordenado	Ordenado, sin solapamiento

No se eliminaron ni imputaron transacciones. La primera prueba deja los nulos originales para reproducir el enfoque básico; la versión final incorpora una categoría de ausencia solo en las copias usadas para medir drift. Las predicciones y los CSV fuente permanecen intactos.

Las clases están casi equilibradas al 50 %. No conviene extrapolar esta prevalencia al fraude bancario real. Las etiquetas suministradas coinciden exactamente con aplicar probabilidad ≥ 0,65: usar 0,50 alteraría 1.889 decisiones del conjunto completo. Se preserva la decisión original.

3. Primera prueba y mejoras

Se dividió el tiempo en meses naturales: 10 bloques de referencia y 8 de producción. Todos los monitores se ajustaron únicamente con reference.csv. La primera prueba ya produjo las tres respuestas finales; la segunda mejoró la interpretación y los controles, sin cambiar esas respuestas.

Componente	Primera prueba	Versión final
Rendimiento	Exactitud estimada y observada, límites de referencia.	Misma exactitud, más precisión, recall, F1, ROC-AUC, AP y calibración.
Ranking	Correlación con referencia y producción juntas (18 meses).	Ranking principal limitado a los 8 meses de producción.
Datos ausentes	Comportamiento estándar de NannyML.	Categoría explícita para transaction_type ausente.
Robustez	Ranking Pearson básico.	Spearman, exclusión de un mes y ajuste BH exploratorio.
Verificación	Inspección de salidas.	Exactitud vs. scikit-learn y medias vs. pandas, tolerancia 1e-12.

Cómo se calcula la señal

CBPE: usa las probabilidades calibradas para estimar aciertos esperados por mes; NannyML determinó que la calibración era necesaria. **Exactitud observada:** proporción de decisiones que coinciden con is_fraud. Una alerta se produce fuera de los límites aprendidos en referencia. [2]

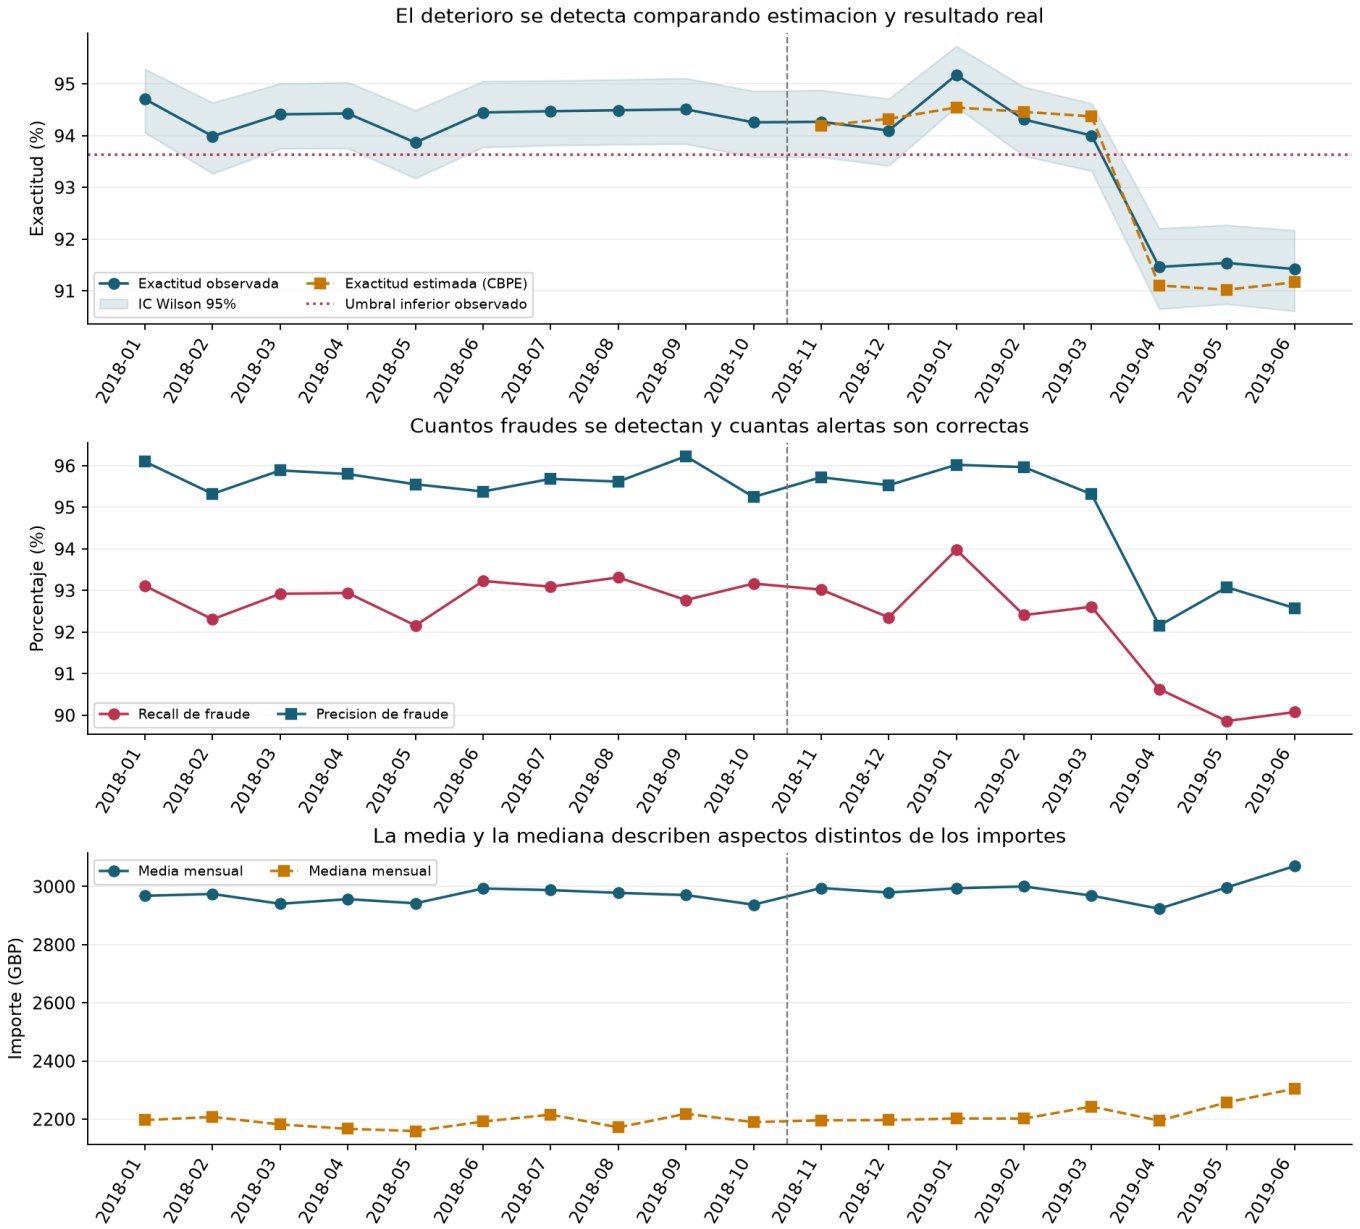
Drift: KS para variables continuas y chi-cuadrado para categóricas. El ranking correlaciona la magnitud del drift con el **cambio absoluto** respecto a la exactitud media de referencia; no es una correlación entre valores de cada transacción y fraude. [3]

Qué aporta la revisión

La correlación de time_since_login_min pasa de 0,9529 (18 meses) a 0,9704 (8 meses de producción). La asociación del importe, en cambio, baja de 0,6262 a 0,5458 y no resulta significativa con ocho puntos. La primera prueba no bastaba para sostener una causa del fallo.

El MAE de CBPE frente a la exactitud observada es de 0,322 puntos porcentuales en los ocho meses. Es una validación retrospectiva del caso, no una garantía futura: cambios en la relación entre variables y etiquetas pueden invalidar la estimación. [2]

4. Evolución del modelo



La línea vertical marca el comienzo de producción (noviembre de 2018). El intervalo Wilson de la exactitud observada expresa incertidumbre muestral aproximada, bajo independencia de observaciones; no sustituye a los límites de alerta ni corrige posible dependencia entre transacciones.

Lectura del resultado

En abril-junio, la caída aparece tanto en la exactitud real como en la estimada. También empeoran el recall y la precisión de fraude. La media del importe activa alerta en junio, mientras que la mediana ayuda a distinguir cambios de localización de cambios en las colas de la distribución.

La exactitud por sí sola no describe el coste operativo: recall bajo implica fraudes no detectados y precisión baja implica más alertas erróneas. El archivo monthly_metrics.csv conserva ambos, junto con matrices de confusión, ROC-AUC, average precision (AP), Brier y error de calibración por bins.

5. Respuestas verificadas mes a mes

Mes	Estimada %	Observada %	Alerta est.	Alerta obs.	Ambas
2018-11	94.195	94.268	No	No	No
2018-12	94.325	94.100	No	No	No
2019-01	94.545	95.176	No	Sí	No
2019-02	94.461	94.312	No	No	No
2019-03	94.374	94.004	No	No	No
2019-04	91.105	91.463	Sí	Sí	Sí
2019-05	91.024	91.541	Sí	Sí	Sí
2019-06	91.166	91.423	Sí	Sí	Sí

Los límites de exactitud son **93.6367 %** y **95.0808 %**. Enero de 2019 supera el límite superior en la exactitud observada, pero no presenta alerta estimada. Por eso no entra en la intersección solicitada. Abril, mayo y junio cruzan el límite inferior en ambas medidas.

Importe medio que activa alerta

Concepto	Valor
Mes	Junio de 2019
Media mensual	£3,069.82 (valor sin redondear: 3069.8183551968)
Límite superior	£3,021.41
Límite inferior	£2,908.43
Exceso sobre el límite superior	£48.41
Variable entregada	alert_avg_transaction_amount = 3069.8184

£3.069,82 es la media observada en el mes con alerta. No es el umbral que dispara la alerta: ese límite superior es £3.021,41. Ambos se calcularon y se conservaron por separado. [4]

Precisión de las salidas

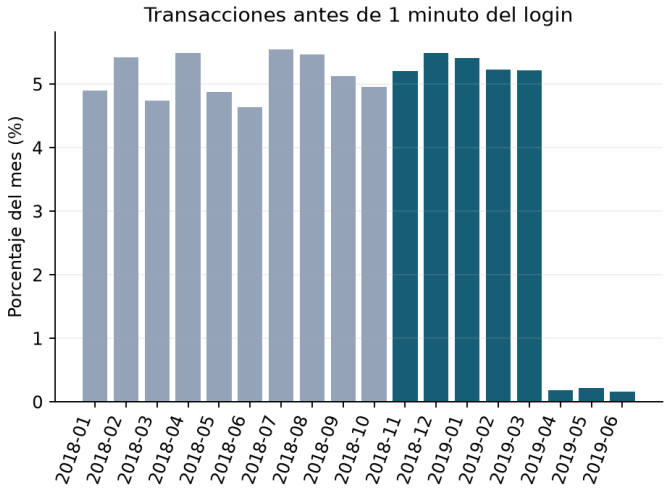
La media se entrega con cuatro decimales, cumpliendo el mínimo de uno. Los nombres de los meses están en inglés, en minúsculas y unidos al año por guion bajo, como exige el corrector. El código deriva las respuestas de las tablas, sin fijarlas de antemano.

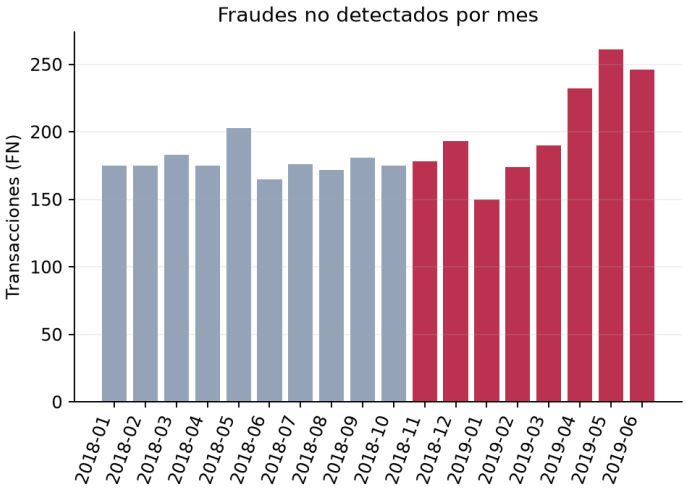
6. Diagnóstico y robustez

Variable	Pearson r	p ajustada BH	Spearman r	r al retirar un mes
time_since_login_min	0.9704	0.000318	0.5238	0.961 a 0.988
transaction_amount	0.5458	0.4043	0.3095	0.265 a 0.808
is_first_transaction	-0.2149	0.6093	-0.0238	-0.381 a -0.047
transaction_type	-0.2381	0.6093	0.2619	-0.447 a -0.089
user_tenure_months	-0.4024	0.5384	-0.2857	-0.538 a -0.257

time_since_login_min conserva una correlación Pearson de 0,961-0,988 al excluir un mes. Su drift KS sigue siendo significativo en abril-junio tras ajustar 40 contrastes (5 variables × 8 meses) con Benjamini-Hochberg. El importe solo conserva significación en junio; la antigüedad, en enero.

La correlación Spearman del tiempo desde el login es 0,5238 (p = 0,1827): la evidencia Pearson fuerte parece describir principalmente un cambio de régimen, no una relación monotónica demostrada. Ocho meses y posible dependencia temporal limitan las p-valores; el ajuste BH es una comprobación exploratoria.





Periodo de producción	Antes de 1 minuto	Fraudes no detectados	Tasa FN entre fraudes
Nov. 2018-mar. 2019	1325 / 24938 (5.31 %)	885	7.12 %
Abr.-jun. 2019	28 / 15029 (0.19 %)	739	9.82 %

Los periodos tienen duraciones distintas: se comparan tasas, no los totales brutos de FN. El descenso de operaciones rápidas se observa en ambas clases. Investigar cambios de captura del login, flujo de la aplicación y composición de usuarios, además de posibles cambios de comportamiento.

7. Qué mejorar y cómo decidir

Prioridad	Acción propuesta	Evidencia y criterio de decisión
Alta	Revisar la definición y captura de time_since_login_min desde abril.	La señal cambia en ambas clases. Contrastar registros de aplicación y cambios de instrumentación.
Alta	Investigar FN y FP por tipo, importe y antigüedad.	La tasa FN entre fraudes pasa de 7,12 % a 9,82 %. Revisar casos confirmados y demora de etiquetas.
Alta	Mantener alertas de recall, precisión y calibración además de accuracy.	Separar deterioro, mejora inusual y desacuerdo estimación-realidad. Medir carga de revisión humana.
Media	Revisar los importes y sus cuantiles en junio.	La media supera el límite de referencia; comprobar si el cambio es de mezcla, escala o extremos.
Media	Probar recalibración, umbrales o reentrenamiento con validación temporal.	Comparar por costes FN/FP y capacidad de revisión, con datos futuros reservados. No elegir en el mismo test.
Media	Reevaluar frecuencia y límites del monitoreo.	Mensual resuelve la tarea, pero podría retrasar detección operativa. Probar semanas si hay tamaño suficiente.

Limitaciones que condicionan las conclusiones

La asociación temporal no demuestra causalidad ni permite afirmar un ataque adaptativo. No hay identificadores de usuario, registros de sesión, costes reales, modelo entrenado, datos de entrenamiento ni muestras posteriores a junio. Por ello no se puede medir reincidencia, estimar ahorro real o certificar una recuperación del modelo.

No se reentrenó ni desplegó un modelo alternativo. La mejora realizada corresponde al análisis y a la monitorización. Para una mejora del detector se necesitan datos recientes, definición de costes y un periodo futuro de prueba. Recalibrar CBPE tampoco modifica las decisiones que ya venían en predicted_fraud.

Los umbrales se ajustaron con diez meses de referencia. La estacionariedad y representatividad de ese tramo requieren revisión en un caso real. Las observaciones casi equilibradas de fraude y el carácter educativo impiden trasladar directamente las métricas a todo un banco.

8. Reproducibilidad, controles y fuentes

Archivo o carpeta	Uso
Proyecto_2104_ejecutado.ipynb	Recorrido en español con código y salidas ejecutadas.
codigo_datacamp.py	Solución autocontenida para copiar a una celda de DataCamp.
src/analisis.py	Pipeline de carga, dos pruebas, controles y gráficas.
data/	CSV originales; no se modifican al ejecutar.
output/v1/ y output/final/	Resultados intermedios y finales, rankings, alertas y comprobaciones.
output/monthly_metrics.csv	18 meses de métricas independientes, matrices y estadísticas.
evidence/notebook_original.ipynb	Notebook de partida descargado del DataLab del proyecto.
requirements.txt y README.txt	Versiones y comandos de reproducción.

Controles completados

Validación del esquema, dominios y orden temporal; ausencia de fuga de etiquetas en CBPE; unión de resultados por meses coincidentes; comparación de accuracy con scikit-learn y medias con pandas (tolerancia 1e-12); estabilidad de las respuestas entre v1 y final; conservación de fuentes y registro de versiones.

NannyML 0.13.1; Python 3.11.9; pandas 2.2.3; NumPy 1.26.4; scikit-learn 1.5.2. Se completó un entorno aislado sin conflictos de dependencias y se ejecutaron las siete celdas de código del notebook. Se desactivó la telemetría de NannyML. Su cálculo solo registró una advertencia de API obsoleta de pandas (Series.ravel), sin errores.

Fuentes

[1] DataCamp, proyecto 2104: enunciado y datos originales

[2] NannyML: estimación de rendimiento y supuestos de CBPE

[3] NannyML: CorrelationRanker e implementación

[4] NannyML: monitorización del promedio

Las cifras se calcularon localmente a partir de los CSV originales; una copia pública antigua consultada al inicio no se usó como fuente de datos ni de resultados. Además de los controles locales, el corrector de DataCamp aceptó las tres respuestas. DataLab las reprodujo con Python 3.8 y NannyML 0.12.1, frente al entorno local descrito arriba.

Integridad de los datos

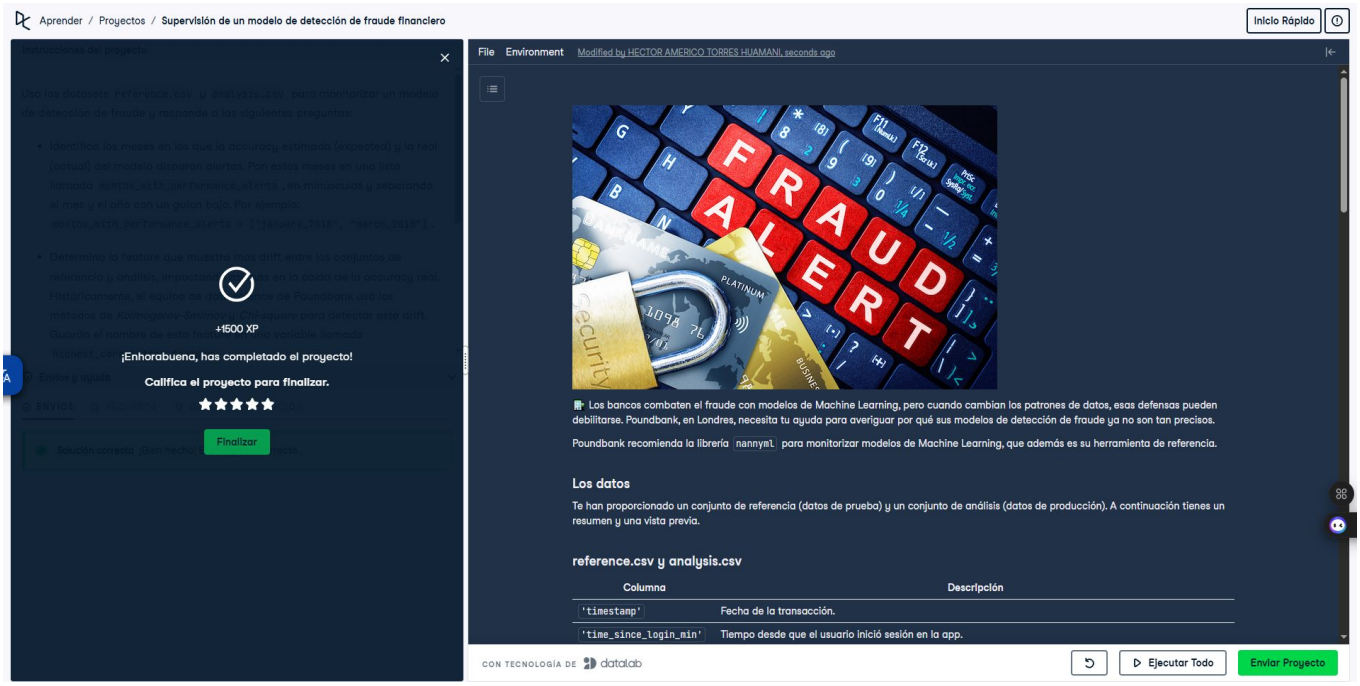
```
reference.csv SHA-256:
7b6cce451bf2759a7faac5a15d481ff5
60c58086b1cd987231bbe631c45d8100

analysis.csv SHA-256:
0c19b7b7f249fc766b7fc4a454f2478c
27d89cc5854aa817fc44eaf9c38369c4
```

9. Aprobación de DataCamp y cierre

Estado final: aprobado. El corrector mostró “Solución correcta” y “¡Bien hecho! El código es correcto.” La plataforma confirmó la finalización del proyecto y otorgó 1500 XP.

Verificación	Evidencia registrada
Fecha local	9 de noviembre de 2026 (America/Lima)
Cuenta	HECTOR AMERICO TORRES HUAMANI
Envío aceptado	Microsoft Edge; mismo cuaderno y misma solución
Archivos de evidencia	evidence/datacamp_aprobado.jpg y evidence/envio_datacamp_estado.json



Captura de la confirmación de finalización y los 1500 XP. El mensaje de aprobación también aparece en el panel de envíos.

Incidencia de envío resuelta

El navegador integrado devolvía un error genérico; cerrar el cuaderno duplicado no lo resolvió. La misma solución fue aceptada desde Edge, sin modificar el código. Esta comparación apunta a un problema de envío del navegador o de su sesión, pero no determina la causa técnica exacta. No fue un rechazo de las respuestas.

Conclusión del proyecto

Se detectó deterioro en abril-junio de 2019, se priorizó investigar el tiempo desde el login y se identificó un importe medio anómalo en junio. La aprobación valida las respuestas del ejercicio; **no demuestra causalidad, recuperación del detector ni idoneidad para producción**. El siguiente paso sería verificar la captura de datos y evaluar mejoras con datos futuros, costes de error y validación temporal.

Abrir el cuaderno aprobado en DataLab